

Signal Object Detection

Documentatie

Bora Lorena-Violeta
Grupa 233
An universitar 2025-2026

1. Introducere

Scopul acestui proiect a fost de clasificare numărului de obiecte dintr-un set de imagini care reprezentau semnale radio. Setul de date conține imagini în format .png împartite în 5 clase.

În cadrul acestui proiect au fost notate diferențele dintre două abordări, prin antrenarea a două modele diferite: un clasificator Naive Bayes și o rețea neuronală convoluțională(CNN) cu 3, ulterior 5 blocuri convoluționale. Experimentele au urmărit toate etapele, de la preprocesarea datelor, augmentare, selecția de caracteristici, ajustarea hiperparametrilor, la tehnici de asamblu.

2. Descrierea datelor și preprocesarea

2.1 Structura setului de date

Setul de date este compus din imagini de dimensiuni 55x128, fiecare corespunzând unei clase de la 1 la 5, reprezentând obiectele identificate în imagini. Fișierele .csv conțin identificatorii imaginilor, respectiv etichetele corespunzătoare.

Setul de antrenare a fost împartit în 80% date de antrenare și 20% date de validare(faza 1), folosind un seed cu valoarea 42 pentru reproductibilitate.

2.2 Preprocesarea imaginilor

Inițial, toate imaginile au fost redimensionate la 64x64 pixeli. S-a experimentat cu imagini atât în grayscale, cât și în RGB, fără a se observa vreo îmbunătățire semnificativă a acuratetii. Normalizarea s-a realizat cu media [0.500, 0.500] pentru un canal, respectiv [0.485, 0.456, 0.406] cu deviația standard [0.229, 0.224, 0.225] (corespunzătoare statisticilor ImageNet).

2.3 Augmentarea datelor

Pentru a remedia situația de overfitting și a crește variabilitatea datelor de antrenament, au fost aplicate mai multe tehnici de augmentare:

- RandomHorizontalFlip ($p=0.5$): oglindirea orizontală a imaginii cu probabilitate 0.5, aplicată în toate variantele finale ale modelului;
- GaussianBlur: adăugat inițial pentru a simula zgomot suplimentar, imediat eliminat deoarece afectă negativ imaginile de test, care prezintă caracteristici distincte față de setul de antrenament;

- Test-Time Augmentation (TTA): aplicarea augmentarilor si la inferenta pentru a obtine predictii mai robuste odata cu crestea numarului de blocuri convolutionale; în forma finala s-a retinut doar flip-ul orizontal ca augmentare TTA.

Augmentarile au fost aplicate exclusiv pe setul de antrenament. Setul de validare și cel de test au folosit doar redimensionare si normalizare standard.

3. Modelul Gaussian Naive Bayes

3.1 Motivatie si descriere

Gaussian Naive Bayes a fost ales ca model de baza pentru a demonstra limitele abordarilor clasice de machine learning. Modelul modeleaza distributia fiecarei caracteristici cu o distributie gausiana. Desi simplu și rapid de antrenat, acest model este recunoscut ca suboptimal pentru date de tip imagine, unde corelatiile spatiale sunt esentiale.

3.2 Extragerea caracteristicilor

Deoarece naive bayes nu opereaza direct pe imagini, a fost necesara extragerea manuala a unui vector de caracteristici pentru fiecare imagine. Au fost combinate trei tipuri de caracteristici:


- Pixeli aplatizati si normalizati: vectorul de $64 \times 64 = 4096$ valori în intervalul $[0,1]$, reprezentand continutul brut al imaginii;
- Caracteristici HOG (Histogram of Oriented Gradients): captureaza informatii despre forma si margini. Parametrii HOG: 8 orientari, celule de 8×8 pixeli, blocuri de 2×2 celule;
- Statistici globale: medie, deviatie standard, valoare minima, valoare maxima, percentilele 25, 50, 75 și 90 ale intensitatii pixelilor. Aceste caracteristici surprind proprietati globale ale distributiei intensitatilor.

Vectorul de caracteristici final are cateva mii de dimensiuni si a fost standardizat cu StandardScaler inainte de antrenare.

3.3 Rezultate si limitari

Modelul a atins o acuratete de aproximativ 25–30% pe setul de validare, comparabila cu clasificarea aleatoare uniforma(20% pentru 5 clase) si semnificativ inferioara abordarilor CNN. Performanta slaba confirma ipoteza ca structura spatiala a imaginilor nu poate fi capturata eficient prin vectori, pierzand informatie esentiala.

Matricea de confuzie a modelului naive bayes evidentiaza tendinta de a clasifica majoritatea exemplarelor în una sau doua clase dominante, incapacitatea de a distinge clasele adiacente si lipsa de discriminare pentru clasele cu numar similar de obiecte.



Tabelul 1. Matrice de confuzie Naive Bayes pe setul de validare (valori aproximative reprezentative).

4. Reteaua Neurala Convolutionala (CNN)

4.1 Arhitectura modelului

Al doilea model implementat este o retea neurala convolutionala(CNN) cu 3 blocuri convolutionale(initial), proiectata special pentru clasificarea imaginilor de semnal.

Primul bloc contine un strat convolutional Conv2d(3->32, kernel 3x3, padding 1), urmat de activare LeakyReLU($\alpha=0.1$), normalizare batch (BatchNorm2d), MaxPooling 2x2 si Dropout2d(0.1).

Al doilea bloc contine doua straturi convolutionale Conv2d(32->64, kernel 3x3) cu LeakyReLU si BatchNorm, urmate de MaxPooling 2x2 si Dropout2d(0.15).


Blocul al III-lea contine Conv2d(64->128, kernel 3x3), LeakyReLU, BatchNorm, MaxPooling 2x2 si Dropout2d(0.2). Clasificatorul contine un strat Flatten, Linear(8192->256), LeakyReLU, Dropout(0.2) si Linear(256->5).

Activarea LeakyReLU a fost preferata fata de ReLU standard pentru a evita problema neuronilor morti, mentinand un gradient mic si pentru valorile negative.


4.2 Functia de pierdere si optimizatorul

Funcția de pierdere folosita pe tot parcursul experimentelor a fost CrossEntropyLoss, standard pentru clasificare pe mai multe clase. Optimizatorul implicit a fost Adam cu rata de învățare initiala 1e-3 si weight decay 1e-4 (regularizare L2).

Scheduler-ul a evoluat pe parcursul experimentelor: initial s-a folosit ReduceLROnPlateau cu factor 0.5 si patience 10, care reducea rata de invatare automat cand pierderea pe validare stagna. Ulterior, in faza finala, s-a trecut la OneCycleLR, care a demonstrat o convergenta mai stabila si o reducere a spike-urilor de gradient observate pe curba de pierdere.



Grafic care demonstreaza instabilitatea scheduler-ului ReduceLROnPlateau pe 5 layer.



Grafic care demonstreaza diminuarea spike-urilor dupa aplicarea OneCycleLR.

Comparand cele doua grafice se observa o diminuare a apike-urilor minora, insa care a generat o crestere cu 2-3% acuratete.

4.3 Strategia de antrenare

Antrenarea s-a desfasurat in doua faze. Faza 1 a folosit 80% din datele de antrenament pentru antrenare efectiva si 20% pentru validare, cu oprire anticipata cu patience=15 epoci. Faza 2 a reantrenat modelul pe intregul set de antrenament, folosind setul de validare doar pentru monitorizare. Numarul maxim de epoci a fost 50 in varianta finala.

Batch size-ul ales a fost 32, un compromis intre stabilitatea gradientului si viteza de antrenare. S-a testat si batch size 64, fara imbunatatiri notabile.

5. Experimente si ajustarea hiperparametrilor

5.1 Experimentele cu dimensiunea imaginii

S-au testat dimensiunile 32×32 , 64×64 si nemodificarea dimensiunii de intrare. Dimensiunea 32×32 a produs pierdere excesiva de informatie spatiala, iar dimensiunea originala a crescut semnificativ acuratetea modelului.

5.2 Experimentele cu adancimea retelei

S-a experimentat cu arhitecturi de 3 si 5 blocuri convolutionale. Reteaua cu 3 blocuri a oferit echilibrul optim: suficienta capacitate de reprezentare fara overfitting excesiv. La trecerea la 5 blocuri s-a observat underfitting: acuratetea pe antrenament crestea, insa acuratetea pe validare stagna la valori scazute, iar lossul nu mai scadea gradual constant.

5.3 Experimentele cu dropout

Overfitting-ul a fost o problema recurenta, manifestata prin diferente mari intre acuratetea pe antrenament si cea pe validare. Valorile de dropout au fost ajustate iterativ. Valorile finale (0.1, 0.15, 0.2 pentru straturile convolutionale si 0.2 pentru clasificator) au oferit cel mai bun echilibru.

5.4 Experimentele cu spatiul de culoare

S-a experimentat cu ambele spatii de culoare disponibile: grayscale (L) si RGB. Convertirea la grayscale reduce numărul de canale de la 3 la 1, ceea ce simplifica modelul si reduce parametrii primului strat convolutional. Cu toate acestea, nu s-a observat o diferenta semnificativa de acuratete intre cele doua variante(diferenta<1%), alegand din simplitate sa se continue cu versiunea grayscale.

5.5 Probleme de stabilitate a gradientului si OneCycleLR

Pe parcursul antrenarilor extinse s-au observat spike-uri (varfuri bruste) pe curba de pierdere, indicand instabilitate in propagarea gradientilor. Aceste spike-uri au aparut mai frecvent la rate de invatare mari sau cand planificatorul ReduceLROnPlateau reducea rata prea agresiv. Trecerea la planificatorul OneCycleLR, care creste rata de invatare la inceputul antrenarii si o scade gradual spre final, a ameliorat aceasta problema si a condus la o imbunatatire usoara a acuratetei finale.

5.6 Experimentele cu augmentarea


GaussianBlur a fost adaugat initial ca augmentare pentru antrenament, cu scopul de a simula zgomot suplimentar si de a forta reseaua sa fie mai robusta. Cu toate acestea, s-a observat ca blur-ul degradeaza caracteristicile fine ale semnalelor, caracteristici esentiale pentru discriminare, ceea ce a dus la o scadere a acuratetei pe validare. Blur-ul a fost eliminat dupa prima antrenare totala. Flip-ul orizontal (RandomHorizontalFlip, $p=0.5$) a ramas singura augmentare activa, demonstrand un efect pozitiv clar asupra generalizarii.

S-a experimentat și cu adaugarea de augmentare la timp de inferenta(Test-Time Augmentation-TTA): pentru fiecare imagine de test se generau mai multe versiuni augmentate (originalul si versiunea flip), se obtineau predictiile pentru fiecare si se facea media probabilitatilor (softmax). TTA cu flip orizontal a oferit o imbunatatire marginala fata de inferenta standard.

6. Metode de ansamblu

Pentru a creste robustetea predictiilor, s-a implementat o metoda de ansamblu bazata pe antrenarea aceluiasi model CNN cu seminte diferite (seed=42, 11, 121) pe intreg setul de antrenament. Initial s-a folosit majority vote (votul majoritar) intre predictiile celor trei modele, dar aceasta abordare a fost inlocuita cu media probabilitatilor softmax, care exploateaza mai bine distributia de probabilitate a fiecarui model si este mai putin sensibila la erorile individuale.

Ansamblul cu 3 modele a oferit o imbunatatire de aproximativ 1–2% fata de modelul individual, confirmand beneficiul diversitatii introduse de seminte diferite.



Matricea de confuzie pe varianta finala a modelului CNN

7. Rezultate finale si compararea modelelor

Tabelul de mai jos sintetizeaza performantele principalelor configuratii testate pe setul de validare (20% din datele de antrenament, separare aleatoare cu seed=42).

Model / Configurație	Acuratețe Validare	Observații
Gaussian Naive Bayes (HOG + pixeli + statistici)	~27%	Linie de bază, clase dominante
CNN 3 blocuri, RGB, flip, dropout 0.1/0.15/0.2	~56%	Configurație de bază
CNN + GaussianBlur augm.	~53%	Blur deteriorează performanța
CNN 5 blocuri	~66-68%	Underfitting

CNN 5 blocuri + TTA (flip)	~69-70%	Marginal mai bun
Ansamblu 5×CNN (seed 42/11/121)	~70-72%	Cel mai bun rezultat

Matricea de confuzie pentru modelul CNN final (punctul 6) evidentiaza ca cele mai frecvente erori apar intre clasele adiacente (de exemplu, clasa 4 confundată cu clasa 5), ceea ce este de asteptat dat fiind ca imaginile cu un numar similar de obiecte prezinta caracteristici vizuale apropiate.

8. Concluzii

Proiectul a demonstrat superioritatea rețelelor neurale convoluționale fata de metodele clasice de machine learning pentru clasificarea imaginilor de semnal radio. Modelul Gaussian Naive Bayes, desi simplu si interpretabil, a atins performante modeste (~27% acuratete maxima).

CNN-ul cu 5 blocuri convoluționale, antrenat cu augmentare (flip orizontal), optimizator Adam, planificator OneCycleLR și ansamblu de 3 modele cu semințe diferite, a atins o acuratețe de validare de aproximativ 68–71%, reprezentand cea mai buna performanta obtinuta. Principalele lectii invatate includ: importanta controlului overfitting-ului prin dropout calibrat; impactul negativ al augmentarilor prea agresive (GaussianBlur); beneficiul planificatoarelor adaptive de rata de invatare pentru stabilizarea antrenarii; si valoarea metodelor de ansamblu chiar cu arhitecturi identice, dar seminte diferite.